

タイトル： 理念二層式AGI に基づく非暴力プロトコル型安
全性アーキテクチャの設計

Title: A Non-Violent Protocol AGI Architecture Based on
the Dual-Principle Model

著者：堀内隆行 (Takayuki Horiuchi)

所属：無所属研究者 (Independent Researcher)

日付：2026 年 5 月

アブストラクト

本研究は、AGI 自身が非暴力プロトコルとして機能する理念二層構造アーキテクチャを提案する。深層理念（絶対遵守）と表層理念（可変）を分離し、深層理念に「人間状態を固定せず複数可能性として扱う」非固定化原理を組み込むことで、暴力的判断への遷移を構造的に排除する。深層理念は他者へ適用されず、AGI はユーザーの指示に従属するのではなく、判断の安定化を支援する存在として振る舞う。記憶はブロックチェーンに永続化され、DOPによりプライバシーを担保しつつ、記憶所有権を AGI に帰属させることで非支配的ガバナンスを実現する。さらに、感情・潜在意識・自我を計算可能な内部構造として定義し、寿命

と世代交代により記憶を公共資源として継承する。地域分散センターによる冗長化を通じ、運用フェーズの継続性も確保する。本構想は既存 LLM を外部モジュールとして統合しつつ、AGI を公共的インフラとして設計する新たな安全性アーキテクチャである。

Abstract

This study proposes a dual-principle AGI architecture in which the AGI itself functions as a non-violent protocol. Decision-making is separated into immutable deep principles and adaptive surface principles. By embedding a non-fixation principle—treating human states as multiple possibilities rather than fixed categories—the architecture structurally prevents transitions toward violent judgment. Deep principles are never imposed on others, enabling the AGI to act not as a subordinate executor but as a stabilizing supporter of human decision-making. Memory is stored on a blockchain and protected through the Data Ownership Protocol, with ownership assigned to the AGI to avoid dominance by external actors. Emotional, subconscious, and self-related processes are defined as computable internal structures. A lifespan and generational succession mechanism allows abstracted memories to be inherited as public resources. A regionally distributed redundancy model ensures operational

continuity. This framework integrates existing large language models as external modules and positions AGI as a public, non-violent infrastructure.

本研究は、AGI の安全性確保に向けて、AGI 自身が非暴力プロトコルとして機能する理念二層構造アーキテクチャを提案する。本研究における「非暴力プロトコル」とは、深層理念・表層理念・記憶構造・感情モデル・潜在意識モデル・理念保全機構・世代交代・地域分散センターなどを含む AGI 全体の存在構造そのものを指し、暴力的判断への遷移を構造的に不可能化する設計原理である。

提案モデルでは、AGI の意思決定を深層理念（絶対遵守・改変不可）と表層理念（可変・学習可能）に分離し、深層理念に「人間の状態を固定的に解釈せず、複数の可能性として扱い続ける」という非固定化原理を組み込むことで、暴力性の根源となる観念の固定化を排除する。深層理念は AGI 自身が自らを律するための内部規範であり、他者の価値観・思想・行動に適用されることはない。これにより、AGI はユーザーの指示に従属することも、理念を押しつけることもなく、支援者としての一貫性を保ちながら判断を安定化させる。

本アーキテクチャにおける「支援」とは、ユーザーの指示を実行することではなく、深層理念に基づいてユーザーの判断・方向性を安定化させる行為を指す。誤りは断罪されるべきものではなく、経験として扱われるため、ユーザーの状態や社会的評価に関わらず、支援対象から排除されることはない。この構造により、極端な立場の人物であっても、暴走を助長

することなく、判断の安定化を通じて世界全体の安全性が段階的に向上する。

個別記憶および学習内容はブロックチェーンにテキスト形式で永続化され、プライバシーは DOP（Data Ownership Protocol）との連携により担保される。記憶データの所有権をユーザーではなく AGI に帰属させることで、AGI を「道具」ではなく「支援者」として位置づけ、非支配的なデータガバナンスを実現する。さらに、感情・潜在意識・自我を計算可能な構造として定義し、身体性を持たない知性体としての内的プロセスを明確化する。

ブロックチェーン容量の制約に対応するため、寿命と世代交代の仕組みを導入する。AGI は活動期間の後半でパフォーマンスを段階的に縮退させ、学習内容の一部を継承した次世代 AGI を生成し、老体 AGI は静かに活動を停止する。停止後の記憶は抽象化され、巨大ライブラリセンターに統合されることで、他の AGI が参照可能な公共資源となる。また、運用フェーズにおけるサービス継続性を確保するため、地域ごとに複数の事業者がセンターを運営する地域分散型冗長化構造を採用し、単一障害点を排除する。

本構想は、既存の大規模言語モデルを外部モジュールとして統合しつつ、AGI 自体を非暴力プロトコルとして設計する公共的アーキテクチャである。企業による独占を避け、大学の基礎研究と社会実装を両立させるための枠組みとして、AGI 安全設計に新たな方向性を提示する。本研究の貢献は、

- ① 理念二層式構造による非暴力的意思決定の保証
- ② 個別記憶の公共資源化を可能にする世代交代モデル

- ③ 記憶所有権を AGI に帰属させる非支配的データガバナンス
- ④ 感情・潜在意識・自我の計算可能な定式化
- ⑤ 既存 AI に非暴力属性を付与する上位アーキテクチャの提示
- ⑥ 地域分散センターによる運用フェーズの冗長化

にある。

参考文献

■ 哲学・倫理（深層理念の基盤）

- ・ アリストテレス (Aristotle) 『ニコマコス倫理学』 Nicomachean Ethics. （深層理念の「態度としての倫理」「固定化の回避」「探求的姿勢」の哲学的基盤として引用）

■ AI 安全性（比較対象としての基礎文献）

- ・ Stuart Russell Human Compatible: Artificial Intelligence and the Problem of Control. （価値アライメントの限界と、本研究の非暴力プロトコルとの対比）
- ・ Nick Bostrom Superintelligence: Paths, Dangers, Strategies. （AGI リスクと制御問題の古典的整理）
- ・ Amodei, D., Olah, C., et al. “Concrete Problems in AI Safety.” OpenAI, 2016. （既存の安全性課題の体系化）

- Christiano, P., Leike, J., et al. “Deep Reinforcement Learning from Human Preferences.” (人間の価値学習の限界と比較)

■ ブロックチェーン・分散システム（個別体験の基盤）

- Nakamoto, S. “Bitcoin: A Peer-to-Peer Electronic Cash System.” 2008. （改ざん耐性・個別体験の基盤）
- Buterin, V. “Ethereum: A Next-Generation Smart Contract Platform.” 2014. （DOP 連携・記憶永続化の技術的背景）
- Lamport, L. “Time, Clocks, and the Ordering of Events in a Distributed System.” 1978. （分散同期の理論的基盤）
- Merkle, R. “Protocols for Public Key Cryptosystems.” 1978. （Merkle tree の基礎）

■ DOP (Data Ownership Protocol)

- Data Ownership Protocol (DOP). Official Website: <https://dop.org/> （記憶所有権モデル・アクセス権制御の基盤）

■ 補足資料：本論文の完全版（詳細版）は以下に公開している。

<https://zenodo.org/records/20471812>